Zaldivar Alanis Rodrigo
Aprendizaje Automatizado 1.1

Problema 1. ① Σ total de datos (N) para obtener el denominador de nuestras probabilidades

Clase sí: 6 Total (N) = 6+4=10
Clase no: 4

Las probabilidades (P_i):
$P(Si) = \frac{6}{10} = .6$ $P(No) = .4$

② Entropía de Shannon para datos está definida
$H(S) = \sum_{i=1}^{n} P_i \log_2(P_i)$
Para nuestro caso binario (2 clases) la fórmula extendida es:

$$H(S) = [P(si)\log_2(p(si)) + P(no)\log_2 p(no)]$$

③ Sustituyendo:
Término para "Sí"
$0.6 \times \log_2(0.6) = 0.6(-0.737) \approx 0.4422$
No
$0.4 \times \log_2(0.4) = (0.4)(-1.3219) \approx -0.5287$
$H(S) = -(-0.4422 - 0.5287) = 0.9709$ bits

Intro:
Como el valor se aproxima a 0.9709, el nodo tiene una impureza alta.
Si tuviéramos S = "Sí" y S = "No", la entropía sería exactamente 1. (Máxima incertidumbre)

Zaldivar Alanis Rodrigo

Aprendizaje IA

Problema 2:

1.- Analizando la columna "jugar"

Casos $t = 8$ sí: 4 No: 4

Como la dist. es perfecta, la incertidumbre es máxima.

$$HS = -(0.5 \log_2(0.5) + 0.5 \log_2(0.5)) = 1.0$$

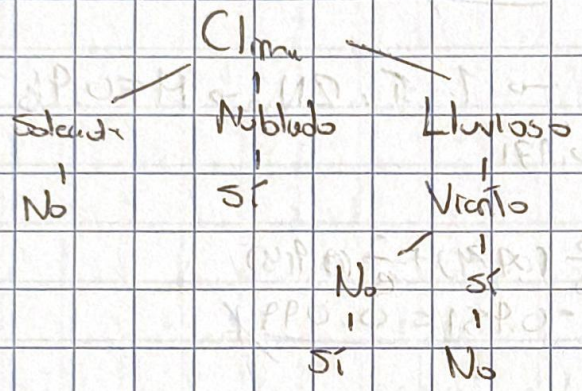

2.- Ganancia de info:

$$IG(S,A) = HS - \sum \frac{|S_v|}{|S|} H(S_v)$$

a.- Clima

Analizamos cada valor del clima respecto a jugar:

- Soleado (3 casos): 0 sí, 3 No → H(Soleado) = 0
- Nublado (2 casos): 2 sí, 0 No → H(Nublado) = 0
- Lluvioso: 2 sí, 1 No → H(lluvioso)

$$= -\left[\frac{2}{3}\log_2\left(\frac{2}{3}\right) + \frac{1}{3}\log_2\left(\frac{1}{3}\right)\right] = 0.918$$

Entropía residual (clima):

$$\frac{3}{8}(0) + \frac{2}{8}(0) + \frac{3}{8}(0.918) = 0.344$$

$$IG(clima) = 0.653$$

Zaldivar Alamo Rodrigo

Aprendizaje

b) H Media

- Alta: 1 sí, 2 No → M = 0.918
- Media: 1 sí, 1 No → M = 1
- Baja: 1 No, 2 sí → 0.918

Entropía residual (Humedad)

$\frac{3}{8}(0.918) + \frac{2}{8}(1) + \frac{3}{8}(0.918) = 0.938$

IG (Humedad) = 1 − 0.938 = 0.062

c Viento: No 5, sí 3 → 1 sí, 2 No → M = 0.918

3 sí, 2 no → M = 0.971

Entropía Res (Viento): $\frac{5}{8}(0.971) + \frac{3}{8}(0.918)$

IG (Viento) = 1.0 − 0.951 = 0.049

3.- Comparando ganancias:

IG (Clima) = 0.656 — Ganador

IG (Humedad) = 0.062, IG (Viento) = 0.049

El nodo raíz del árbol es el Clima

4.- Al dividir por clima:

① Si clima es soleado: Todos los nodos son "No" (Hoja pura)

② Si clima es Nublado: Todos los casos son sí. (Hoja pura)

3.- Si clima = lluvioso: El subconjunto es [sí, sí, no]

Muy ganancia para humedad y viento (calcular)

5.- Repetición para el lluvioso. Observando datos original cuando llueve

- Lluvioso + Humedad Media + Viento No → Sí
- Lluvioso + Humedad Baja + Viento sí → Sí
- Lluvioso + Humedad Baja + Viento sí → No

si hay viento — se juega

No hay viento — No se juega

Zaldivar Alanis Rodrigo

IA - Aprendizaje

Problema 3.-

~~[1,0]~~ [1, 0, 1, 1, 0]

1.- En un problema de clasificación, etiqueta 1, 0. R.F. utiliza votación mayoritaria

- Predicciones y niveles: {1, 0, 1, 1, 0}
- Conteo de votos
  - 1: 3
  - 0: 2
- Resultado 3>2 => 1.

2.- ① La ley de los grandes números. Promediar o votar resultados de distintos modelos independientes, el error aleatorio de cada uno tiende a cancelarse. Un solo árbol puede ser muy sensible al ruido de los datos de entrenamiento. Pero el promedio es más estable.

② Decorrelación: El bootstrapping y selección aleatoria de características, cada árbol "ve" una versión ligeramente distinta al problema. Si los árboles fueran idénticos, la votación sería la misma. Al ser diferentes, sus errores no son iguales.

③ Subdivisión de las masas: Es menos probable que la mayoría de los árboles se equivoquen al mismo tiempo en la misma dirección. Suavizan la frontera de decisión y evitan overfitting.

I.A. ZAR

Problema 4.-

1.- Un T con profundidad es muy complejo por el overfitting. Al ser tan profundo el árbol deja de aprender patrones generales y comienza a memorizar ruido y casos particulares del ds. de entrenamiento.
Consecuencia: Tendrá un error cuando en entrenamiento pero falla con datos nuevos. (Poca capacidad de generalización)

2.- R.F. Combina árboles con ambiguos para forzar generalización mediante:
- Bagging (Bootstrap Aggregating): Cada árbol se entrena con una muestra distinta de datos.
- Feature randomness: En cada división el árbol solo puede elegir entre un subconjunto aleatorio de características. Evita que una sola dominante dicte la estructura de todos los árboles, permitiendo que el bosque capture distintas perspectivas de los datos.

3.- Si eliminamos la aleatoriedad y todos los árboles son idénticos:
1. La varianza no se reduce: El error de un árbol es combinado por todos. Votar entre 100 personas que piensan exactamente igual no aporta nada más.
2. Se pierde la subidentidad de las masas. El ensamble hereda overfitting del árbol individual de profundidad 20.
3. El modelo deja de ser un random forest y se convierte en un árbol individual repetido. Pierde ventaja de aprendizaje por conjunto.

Se comparten errores

ZAR

Problema 5:

1.- Calcula errores

En Boosting, los residuos son la diferencia ± valor real y predicción. Representan "lo que el modelo aún aprende"

La fórmula $r = y - y_{pred}$

- Para $y_1 = 12 - 10 = 2$
- Para $y_2 = 8 - 10 = -2$
- Para $y_3 = 15 - 10 = 5$

Vector residuo [2, -2, 5]

2.- Entrenar: A diferencia de random forest, donde cada árbol intenta predecir y, en Gradient Boosting el sig. modelo se entrena para predecir los residuos generados por el modelo anterior.

El objetivo del árbol 2 será aprender a partir del vector

Interpretación: El modelo intentará entender porqué nos faltó 2 unidades en el primer uso, pero nos pasamos por 2 en el segundo y porqué faltaron 5 en el 3.

3.- Nueva predicción: No recomputa a la anterior, se le suma (~~...~~ multiplicada por una tasa de aprendizaje

$$y_{nueva} = y_{anterior} + (\eta \times predicciones)$$

Si $\eta = 0.1$ y el nuevo modelo predice perfectamente los residuos, vamos a tener para el primer dato

$$10 + (0.1 \times 2) = 10.2$$

Resultado: La predicción se acerca lentamente hacia el valor real. En cada paso el error global disminuye.

Bagging: Árboles ind. en paralelo. El error se reduce promediando

Boosting: Árboles secuencial, Cada árbol intenta corregir los errores del anterior. Reduce sesgo