Zaldívar Alanís Rodrigo

I.A. 16/4/26

~~12~~.

6:

①

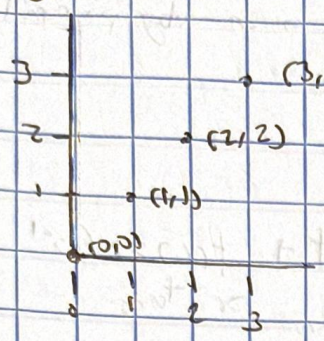

Clase +1 {azul}: (2,2) y (3,3)

Clase -1 {roja}: (0,0) y (1,1)

② Como todos los puntos están sobre $y=x$ son perfectamente separables por una recta perpendicular a que pase entre (2,2) y (1,1).

Una recta que lo separa es $x+y=3$

Con (0,0): $(0+0=0) < 0$, lado -1

Con (1,1) $1+1=2 < 3$, lado -1

Con (2,2) $2+2=4 > 3$, lado 1

Con (3,3) $3+3=6 > 3$, lado 1

Alternativa simétrica

La recta $x+y=3$ está bien, pero también podríamos elegir $x+y=3.5$ o una bisectriz perpendicular exacta entre los puntos más cercanos.

El punto medio entre (1,1) y (2,2) es $(\frac{3}{2}, \frac{3}{2})$

Una recta perpendicular a $y=x$ tiene pendiente -1

Ecuación que pasa por (1.5, 1.5) con $m=-1$ será $y-1.5=-(x-1.5)$

$y=-x+3$.

③ Los vectores de soporte en SVM son los puntos más cercanos al margen de separación. Aquellos que sostienen el margen máximo.

Entre los puntos de una clase y otra, la menor distancia entre el plano de características aquí es el mismo plano (x,y) ocurre entre (1,1) de -1 y (2,2) de la clase +1. ∴ Vectores de soporte (1,1) y (2,2). Puntos (0,0) y (3,3) No son de soporte por estar más lejos de $x+y=3$. No definen el margen

ZAR

Problema 7:

① Un SVM lineal busca separar las clases mediante una línea recta en 2D o un hiperplano en dimensiones superiores. Si los datos están mezclados, de tal forma que ∄ línea recta capaz de dividir los grupos sin cometer errores mayores (como cuando una clase rodea la otra). El modelo lineal simplemente no puede encontrar una solución válida. ∴ falla cuando los datos no son linealmente separables.

② El truco del kern permite proyectar los datos de su espacio original a un espacio de mayor dimensión donde sí sean linealmente separables sin necesidad de calcular explícitamente esa transformación.

Beneficios:

1. Encontrar separaciones no lineales en el espacio original
2. Mantener la eficiencia computacional del SVM lineal.
3. Usar funciones como polinomial, RBF sigmoide

Fórmula clave:

$K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$. El SVM trabaja con productos punto en el espacio transformado $\phi(x)$

ϕ lleva los datos a un espacio más complejo para que el SVM funcione mejor

③ Imagina un tiro al blanco, los puntos rojos son el centro y los puntos azules son el anillo exterior. No puedes pasar una línea recta que los separe. Al aplicar un Kernel RBF (Radial Basis Function)

$$K(x,y) = \exp\left[-\frac{\|x-y\|^2}{2\sigma^2}\right]$$

- El modelo mide la distancia a cada punto hacia el centro
- Los puntos del centro (rojos) se elevan en una tercera dimensión (z) mientras que los anillos azules se quedan abajo.
- Se puede pasar por un plano horizontal como una hoja de papel entre los puntos elevados y los puntos de abajo. La proyección del corte a 2D es un círculo.

④ Un ejemplo clásico es el reconocimiento de rostros o la clasificación de imágenes complejas. Los pixeles de una imagen no tienen una relación lineal sencilla. Las características que definen algún objeto dependen de combinaciones no lineales de luz y sombra. Un Kernel permite al SVM entender esas fronteras curvas y complejas para distinguir entre diferentes cosas o personas.

Zaldivar Alvarez Rodrigo

Ejercicio 8: Para clasificar el nuevo punto (3,3) observamos las

① distancias, usando las distancias euclidiana. Por inspección visual, como todos están en la misma diagonal $y=x$.

Clase A distancia a (2,2) $\sqrt{(3-2)^2+(3-2)^2} = \sqrt{2} =$

Clase B dist a (4,4) $\sqrt{(3-4)^2+(3-4)^2} = \sqrt{2}$

Como (3,3) está a la misma distancia pero en caso de empate se elige al azar o por aperturas.

* Para $K=1$ buscamos al vecino más cercano (2,2) de la clase A o (4,4) de la clase B. Ya que ambos están a la misma distancia mínima

② Con $K=3$ buscamos los 3 vecinos más cercanos:

(2,2) Clase A. Distancia 1.41

(4,4) B dist. $\sqrt{2}$

(1,1) A dist 2.82

Al hacer la votación

Votos clase A: 2 (2,2) y (1,1)

1 voto clase B (4,4)

La ganadora es la clase A.

③ Lo que cambia es la estabilidad de la predicción y la sensibilidad del ruido - con K pequeña ($K=1$) el pez modelo es muy sensible

Si (2,2) fuese ruidoso o un error de medición, la predicción cambiará por completo.

Es un modelo con tendencia al overfitting

- Con K más grande ($K=3$) la decisión se vuelve más democrática

Al considerar más vecinos, el modelo suaviza la frontera de decisión y es menos probable que un solo dato atípico arruine la clasificación

Eulalia Alanis Rodrigo

Problema 9:

① KNN calcula distancias euclidianas, por lo general entre puntos

Problema:

edad: rango 0-100

ingreso 0-1M

La escala del ingreso es mucho mayor (millones comparados con la edad)

∴ La distancia es

$$d = \sqrt{(edad_i - edad_j)^2 + (ingreso_i - ingreso_j)^2}$$

La diferencia en ingreso domina completamente la distancia

Consecuencias prácticas

- La variable edad prácticamente no influye en la clasificación
- El algoritmo se comporta como si solo usara el ingreso, perdiendo información valiosa
- Vecinos cercanos salen casi exclusivamente por similitud en ingreso.

② Sol: Escalar variables para que tengan magnitudes comparables.

Existen 2 técnicas comunes

a) Normalización (Min-max scaling): llevar los datos a un rango fijo, [0,1]:

$$x' = \frac{x - min(x)}{max(x) - min(x)}$$

Aplicando edad

normalizada a [0,1]

ingreso normalizado a [0,1], ambas variables contribuyen por igual a la distancia

b) ~~Estandarización~~ Estandarización (Z-score-scaling)

$\mu_{edad} = 0$ desviación estándar $= 1$

$$x' = \frac{x - \mu}{\sigma}$$

. Útil para outliers.

Zaldar Alvaro Rodrigo

Problema 10:

Naive Bayes asume que las características (A y B) son independientes entre sí dada la clase, la fórmula simplificada para la probabilidad posterior así

$$P(clase \mid A,B) \propto P(A \mid Clase) \cdot P(B \mid clase) \cdot P(Clase)$$

① $P(A \mid Spam) = 0.6$

$P(B \mid Spam) = 0.7$

$P(Spam) = 0.4$

$P(Spam \mid datos) \propto (0.6)(0.7)(0.4) = \underline{0.168}$

②

$P(A \mid No\ spam) = 0.2$

$P(B \mid No\ spam) = 0.3$

$P(No\ Spam) = 0.6$

$P(No\ Spam \mid datos) \propto (0.2)(0.3)(0.6) = \underline{0.036}$

③

Comparamos ambos resultados y clasificar dado el mejor. Es spam debido a que $0.168 > 0.036$

④ No. Casi nunca existe existe una independencia absoluta entre las características. Por eso el algoritmo se llama ingenuo.